

# 1、总结 DeepSeekV3 相比 DeepSeekV2 改进；

## DeepSeek V2总结

用 **MLA** 降低推理时的 KV Cache，用 **DeepSeekMoE** 降低训练成本；它有 236B 总参数、每个 token 激活 21B 参数，训练语料为 8.1T tokens，支持 128K 上下文。论文称，相比 DeepSeek 67B，V2 节省 42.5% 训练成本、减少 93.3% KV Cache、最大生成吞吐提升到 5.76 倍

---

## V2 解决的主要问题是什么？

V2 想解决的是一个很现实的问题：

**大模型越大，越聪明，但训练和推理都越来越贵。**

所以 V2 的论文标题里有三个关键词：**Strong、Economical、Efficient**，也就是“强、便宜、高效”。它的主要做法有两个。

第一个是 **MLA，多头潜在注意力**。你可以把它理解成：传统大模型在生成文本时，需要把前文的很多注意力信息都存下来，也就是 KV Cache。上下文越长，KV Cache 越大，显存压力越高，推理越慢。MLA 的做法是把这些 Key 和 Value 压缩成更小的 latent vector，相当于给“记忆”做压缩存储。V2 论文明确说，MLA 的目的就是减少推理阶段 KV Cache 瓶颈，同时尽量不牺牲模型效果。

第二个是 **DeepSeekMoE**。MoE 可以理解为“专家团队”：模型里面有很多专家，但每次处理一个 token 时，只激活其中一部分专家。这样模型总参数可以很大，但每次计算成本不会按总参数全额支付。V2 是 236B 总参数，但每个 token 只激活 21B 参数，这就是它“又大又省”的关键。

所以，V2 的本质是：**用 MLA 解决推理显存和速度问题，用 MoE 解决训练和计算成本问题。**

---

## MLA

<https://zhuanlan.zhihu.com/p/16730036197>

## DeepSeek MOE

DeepSeek-MOE原理讲解\_哔哩哔哩\_bilibili

## DeepSeek v3 总结

V3 的核心思路不是推翻 V2，而是**继承 V2 的 MLA + DeepSeekMoE**，然后进一步扩大到 671B 总参数、每个 token 激活 37B 参数，并加入 **无辅助损失负载均衡、多 Token 预测 MTP、FP8 训练、DualPipe 通信计算重叠**等改进。V3 训练语料扩大到 14.8T tokens，全训练成本为 2.788M H800 GPU hours，论文称其开源模型表现接近领先闭源模型。

## V3 相对 V2 改了什么？

### 改进 1：规模变大了，但不是简单堆参数

V2 是 **236B 总参数、21B 激活参数**；V3 是 **671B 总参数、37B 激活参数**。这说明 V3 的“专家池”更大，每次实际调用的专家也更多，因此能力上限更高。

但这里要注意：V3 不是传统意义上把所有参数都一起算的 Dense 模型，而仍然是 MoE。也就是说，它不是每次都用 671B 参数，而是每个 token 激活 37B 参数。通俗说，**V3 是把专家库扩得更大，但每次仍然只请一部分专家上场。**

---

### 改进 2：V3 继承了 V2 的 MLA 和 DeepSeekMoE

V3 论文自己说，V3 仍然采用 V2 已经验证过的 **MLA** 和 **DeepSeekMoE**。这说明 V3 的路线不是“另起炉灶”，而是认为 V2 的基础架构已经有效，然后在这个基础上继续放大。

V3 对 V2 的改进不是架构范式的彻底替换，而是在 V2 成功验证的 MLA + DeepSeekMoE 路线上进行规模化、训练目标和工程效率升级。

---

### 改进 3：负载均衡从“加惩罚项”变成“动态调路由”

MoE 模型有个问题：如果某些专家总被选中，某些专家总没人用，就会造成“专家拥堵”和“专家浪费”。V2 采用的是辅助损失，也就是额外加一些约束，让专家使用尽量均衡。V2 论文里提到，它设计了专家级、设备级和通信级的辅助损失来控制负载均衡。

V3 改成了 **auxiliary-loss-free load balancing**，也就是“无辅助损失负载均衡”。通俗理解：V2 像是在训练目标里额外加一个“别偏科”的扣分项；V3 则是在路由时动态调整每个专家的吸引力，让过热专家少接一点活，冷门专家多接一点活。论文说，这样做是为了减少负载均衡对模型性能的负面影响，并且 V3 训练中不需要 token dropping。

这就是 V3 相比 V2 的一个关键进步：**既保持专家使用均衡，又尽量不伤害模型本身的学习能力。**

---

### 改进 4：加入 MTP，让模型一次学会预测多个未来 token

V2 主要还是常规的“预测下一个 token”。V3 加入了 **Multi-Token Prediction, MTP, 多 Token 预测**。通俗地说，以前模型像学生做题时只被要求“预测下一步”；V3 训练时还要求它多看几步，尝试预测后面几个 token。论文认为这会让训练信号更密集，也可能帮助模型提前规划内部表示。

这个改进的意义是：**训练时给模型更多学习信号，让模型不只是盯着眼前一个词，而是学会更长一点的连续预测。**

V3 论文还说，MTP 主要用于提升主模型性能，推理时可以直接丢弃 MTP 模块；也可以把它用于 speculative decoding，从而降低生成延迟。

---

## 改进 5：训练工程大升级，特别是 FP8 和 DualPipe

V3 很重要的一点是工程优化。它支持 **FP8 混合精度训练**，并通过 FP8 计算和存储来加速训练、减少显存占用；同时设计了 **DualPipe**，让计算和通信尽量重叠，减少 MoE 跨节点通信带来的等待。

通俗理解：MoE 模型像一个跨城市协作的大团队，专家分布在不同机器上。如果通信慢，大家等来等去，效率就低。V3 的 DualPipe 和通信优化，就是让“专家之间传资料”和“专家自己干活”尽量同时进行，少等。论文称，这种算法、框架和硬件协同设计显著提高了训练效率，降低了训练成本。

---

## 改进 6：训练数据更多，后训练也更强

V2 预训练数据是 **8.1T tokens**；V3 扩大到 **14.8T tokens**。

此外，V3 的后训练阶段还引入了来自 DeepSeek-R1 系列模型的推理能力蒸馏。简单说，就是把更擅长长链推理的模型中的“反思、验证、推理模式”迁移给 V3，让 V3 在保持普通模型输出风格的同时提升推理能力。

DeepSeek V3 MTP [https://www.bilibili.com/video/BV1jA9HYfEAC?vd\\_source=90a70119aef139acc4242a6c850c456f&spm\\_id\\_from=333.788.videopod.se](https://www.bilibili.com/video/BV1jA9HYfEAC?vd_source=90a70119aef139acc4242a6c850c456f&spm_id_from=333.788.videopod.se)